

TALLER 1

Imaginar, ordenar y explicar datos en R

Del Excel "visual" a una base tidy y reproducible

Regla central del taller

Antes de ejecutar: predecir. Después de ejecutar: comparar. Finalmente: explicar.

Dr. Ian Acuña

Magíster en Ecología Aplicada · Universidad de Talca

Julio de 2026

1. Propósito del taller

Este taller busca desarrollar una habilidad central para trabajar con datos: **imaginar la forma de una tabla antes y después de transformarla**. El objetivo no es memorizar funciones, sino comprender qué entra, qué cambia y qué sale en cada operación.

Se permite utilizar apuntes, cheatsheets, internet, compañeros y herramientas de inteligencia artificial. Sin embargo, cada estudiante deberá **explicar personalmente el código** en un video breve. La evaluación se centrará en la comprensión y no en la capacidad de copiar o producir código sin entenderlo.

2. Productos de entrega

- Hoja o fotografía con las predicciones realizadas antes de ejecutar el código.
- Ficha de predicción de los ejercicios de subconjuntos con corchetes (Sección 4).
- Script de R utilizado en la sección guiada y en la aplicación a datos propios.
- Archivo Excel o CSV tidy producido a partir del archivo desordenado asignado.
- Archivo con un subconjunto de los datos, separado por un nivel de un factor.
- Video individual de máximo 2 minutos explicando el código aplicado a sus datos.

3. Glosario mínimo

Concepto	Descripción
Objeto	Elemento almacenado en R bajo un nombre. Puede ser un número, vector, tabla, modelo o gráfico.
Vector	Secuencia de valores del mismo tipo (todos numéricos, todos texto, etc.). Cada columna de un data frame es, internamente, un vector.
Directorio de trabajo	Carpeta donde R busca y guarda archivos por defecto. Se revisa con <code>getwd()</code> . Si el archivo "no se encuentra", casi siempre es un problema de directorio de trabajo, no del archivo.
Data frame / tibble	Tabla rectangular donde las filas representan observaciones y las columnas representan variables.

Observación	Unidad representada por una fila: una planta, parcela, muestra, persona, fecha, etc.
Variable	Característica registrada en una columna: especie, sitio, tratamiento, biomasa, temperatura, etc.
Clase / tipo de dato	Categoría interna de un objeto en R: numeric, character, logical, factor, etc. Se revisa con class(). De esto depende qué operaciones son válidas.
Función	Instrucción que recibe información, realiza una tarea y devuelve un resultado (lo que viene antes del paréntesis "(").
Argumento	Información que se entrega dentro de una función para controlar su comportamiento (lo que está dentro del paréntesis, separado por comas).
Factor	Variable categórica con niveles definidos.
NA	Valor ausente. No significa cero.
Operador lógico	Comparación que devuelve TRUE o FALSE: == (igual), != (distinto), > , < , >= , <= , %in% (pertenece a un conjunto), & (Y), (O), ! (negación).
Posición (índice numérico)	Lugar que ocupa un elemento dentro de un vector, fila o columna, contando desde 1: por ejemplo, plantas[3,] selecciona la tercera fila. No debe confundirse con el id/llave usado para unir tablas.
Pipe %>%	Operador que envía el resultado de una instrucción a la siguiente.
Tidy data	Estructura donde cada variable ocupa una columna, cada observación una fila y cada valor una celda.
id / llave / key	Variable que identifica observaciones y permite unir tablas correctamente: el valor que permite unir dos tablas juntando casos que comparten el mismo valor.
Grupo	Conjunto de observaciones que comparten uno o más niveles de variables categóricas.

4. Antes de empezar: cargar sus datos y subconjuntos con corchetes []

4.1 Cargar su base a R

Antes de poder trabajar con estos datos, cárguenlos en su propia sesión de R: definan su directorio de trabajo (working directory) y carguen los paquetes necesarios (por ejemplo, readxl). Esa parte no se la doy resuelta — revisen sus apuntes o la cheatsheet correspondiente para recordar cómo se hace. Una vez hecho eso, descarguen plantas_taller.xlsx y úsenlo con estas líneas:

```

Seccion 4.1 - cargar (escribir a mano, no copiar/pegar)
1 plantas <- read_excel(
2   path = "plantas_taller.xlsx",
3   sheet = "datos"
4 )
5
6 plantas

```

Yo llamaré a mi objeto *plantas* a lo largo de todo este documento. Ustedes pueden llamarlo como prefieran (por ejemplo *mis.plantas* o *base1*) — solo asegúrense de usar el mismo nombre de forma consistente en todo su código.

4.2 Subconjuntos con corchetes []

Antes de llegar a `group_by()` y `summarise()`, conviene dominar la forma más básica de "cortar" una tabla: los corchetes. La sintaxis general es `objeto[filas, columnas]` — dejar un lado vacío significa "todas". Además de indicar posiciones, dentro de los corchetes se pueden usar operadores lógicos para quedarse solo con las filas que cumplen una condición: `==` (igual), `!=` (distinto), `>` y `<` (mayor/menor), `>=` y `<=` (mayor o igual/menor o igual), `%in%` (pertenecer a un conjunto de valores), `&` (Y, deben cumplirse ambas condiciones), `|` (O, basta con que se cumpla una) y `!` (negación).

```

Seccion 4.2 - subsetting (escribir a mano, no copiar/pegar)
1 # sintaxis general: objeto[filas, columnas]
2 plantas[1, ]
3 plantas[, 1]
4 plantas[1:3, ]
5 plantas[, c("especie", "altura")]
6
7 # con operadores logicos (==, !=, >, <, >=, <=, %in%, &, |, !)
8 plantas[plantas$especie == "maiten", ]
9 plantas[plantas$altura > 15, ]
10 plantas[plantas$especie == "quillay" &
11   plantas$tratamiento == "poda", ]
12 plantas[plantas$especie == "quillay" |
13   plantas$especie == "tara", ]
14 plantas[plantas$especie %in% c("maiten", "tara"), ]
15 plantas[!is.na(plantas$biomasa), ]

```

Antes de ejecutar cada línea: dibuje o describa en papel cómo se vería el resultado (cuántas filas, cuántas columnas, qué contiene). Complete al menos estas cuatro filas de la ficha antes de correr el código:

Expresión	Filas esperadas	Columnas	Qué contiene
-----------	-----------------	----------	--------------

		esperadas	(describalo)
plantas[plantas\$especie == "quillay" & plantas\$tratamiento == "poda",]			
plantas[plantas\$especie == "quillay" plantas\$especie == "tara",]			
plantas[plantas\$especie %in% c("maiten", "tara"),]			
plantas[!is.na(plantas\$biomasa),]			

5. Actividad 1: reconocer una base que no es tidy

A cada estudiante se le asignará un archivo Excel diferente (ver tabla de asignación en el Anexo, al final de este documento). Los archivos representan situaciones frecuentes en investigación: múltiples tablas en una misma hoja, encabezados repetidos, resultados calculados dentro de la base, celdas vacías, colores usados como información, tiempos o tratamientos distribuidos en columnas, y factores separados en hojas diferentes.

¿cómo están organizados los datos?

	A	B	C	D	E	F	G	H	I	J
1		TSA								
2		48 h				72 h			96	
3		OS	OTC			OS OTC			OS OTC	
4		1	1			0 0			0 0	
5		1	0			0 0			0 0	
6		1	0			0 0			0 0	
7		0	0			0 0			0 0	
8		0	0			0 0			0 0	
9	Sumatoria	3	1			0 0			0 0	
10	media	0.6	0.2			0 0			0 0	
11	desv	0.54772256	0.4472136			0 0			0 0	
12	UFC/gr	60	20			0 0			0 0	
13										
14		PON								
15		48 h				72 h			96	
16		OS	OTC			OS OTC			OS OTC	
17		0	1			0 0			0 0	
18		0	1			0 0			0 0	
19		0	1			0 0			0 0	
20		0	0			0 0			0 0	
21		0	0			0 0			0 0	
22	Sumatoria	0	3			0 0			0 0	
23	Media	0	0.6			0 0			0 0	
24	Desv	0	0.54772256			0 0			0 0	
25	UFC/gr	0	60			0 0			0 0	

Figura 1. Ejemplo de un Excel diseñado para lectura visual, pero no para análisis reproducible.

5.1 Antes de modificar el archivo

1. ¿Qué representa una observación en este archivo?
2. ¿Qué información corresponde a variables y debería estar en columnas?
3. ¿Qué información aparece como títulos, colores, posiciones o nombres de hojas?
4. ¿Hay cálculos —promedios, sumatorias o desviaciones— mezclados con los datos originales?
5. ¿Existen celdas combinadas, encabezados múltiples o filas vacías?
6. ¿Qué variables deberían convertirse en factores?
7. ¿Qué información debería reunirse en una sola tabla?
8. ¿Pueden cargar esas hojas de Excel a R? Inténtenlo.

5.2 Diseña la tabla tidy antes de construirla: ¿cómo me la imagino?

Dibuje en papel una propuesta de cómo debería ser la tabla tidy. Debe incluir los nombres de las columnas y al menos seis filas de ejemplo. Para un archivo como el de la figura, una posible estructura sería:

temp	medio	tiempo_h	condicion	replica	respuesta	valor_ufc.g
5	TSA	48	OS	1	1	60
5	TSA	48	OS	2	1	60
5	TSA	48	OTC	1	1	20
5	PDN	48	OTC	1	1	60
10	TSA	72	OS	1	0	0
20	PDN	96	OTC	3	0	0

Principio clave: los niveles de una variable —por ejemplo, 5 °C, 10 °C y 20 °C— deben aparecer como valores dentro de una columna, no como hojas independientes ni como bloques separados.

5.3 Transformación esperada

Deben entregarme el Excel que les envié, pero esta vez sumando en una nueva hoja la tabla tidy, es decir, formateada para ser llamada desde R. Esta manipulación es a mano, no se hace desde R (usualmente porque desde R no se "deja llamar" un Excel así) — es lo que hay que hacer a mano antes de "llamar" la tabla a R.

Importante: un archivo visualmente bonito no necesariamente es una base de datos bien estructurada. La tabla tidy debe privilegiar consistencia, trazabilidad y facilidad de análisis.

6. Actividad 2: sección guiada — group_by() y summarise()

Esta sección funciona como una pequeña clase. Transcriba cada bloque desde la imagen entregada (no se puede copiar y pegar: hay que tipearlo), ejecútelo y complete la predicción antes de ver el resultado. La base plantas ya quedó cargada en la Sección 4; si abrió una sesión nueva de R, cárguela de nuevo antes de continuar.

6.1 Revisar la base de juguete

```
Seccion 6.1 - revisar base (escribir a mano, no copiar/pegar)
1 plantas
2 dim(plantas)
3 names(plantas)
4 str(plantas)
5 summary(plantas)
```

Antes de continuar, responda: ¿cuántas filas y columnas tiene la base? ¿Qué representa una fila? ¿Cuáles variables son numéricas? ¿Cuáles representan categorías? ¿Existen valores ausentes?

6.2 summarise() sin grupos

```
Sección 6.2 - summarise sin grupos (escribir a mano, no copiar/pegar)
1 plantas %>%
2   summarise(
3     altura_promedio = mean(altura)
4   )
```

Prediga: ¿cuántas filas y columnas tendrá el resultado? ¿Qué representa la única fila?

6.3 group_by() no resume por sí solo

```
Sección 6.3 - group by solo (escribir a mano, no copiar/pegar)
1 plantas %>%
2   group_by(especie)
3
4 # group_by() no elimina filas ni calcula nada por sí solo:
5 # solo deja la tabla "marcada" para la siguiente operación
```

group_by() organiza temporalmente las observaciones en grupos, pero normalmente no elimina filas ni calcula estadísticas. Prepara la tabla para que la siguiente operación se ejecute por separado dentro de cada grupo.

6.4 Agrupar y resumir

```
Sección 6.4 - agrupar resumir (escribir a mano, no copiar/pegar)
1 plantas %>%
2   group_by(especie) %>%
3   summarise(
4     altura_promedio = mean(altura),
5     altura_sd = sd(altura),
6     n = n()
7   )
```

Antes de ejecutar, reflexione sobre:

Número esperado de grupos	
Número esperado de filas	
Número esperado de columnas	
Qué representa cada fila	
Qué cuenta n()	

6.5 Agrupar por dos variables

```
Seccion 6.5 - agrupar dos variables (escribir a mano, no copiar/pegar)
1 plantas %>%
2   group_by(especie, tratamiento) %>%
3   summarise(
4     altura_promedio = mean(altura),
5     biomasa_promedio = mean(biomasa, na.rm = TRUE),
6     n = n()
7   )
```

Escriba todas las combinaciones de especie y tratamiento que realmente existen. El resultado tendrá una fila por cada combinación presente, no necesariamente por todas las combinaciones teóricas posibles.

6.6 Valores ausentes

```
Seccion 6.6 - valores ausentes (escribir a mano, no copiar/pegar)
1 mean(plantas$biomasa)
2 mean(plantas$biomasa, na.rm = TRUE)
```

Explique la diferencia. Recuerde que `na.rm = TRUE` elimina los valores ausentes solo para realizar el cálculo; no corrige ni explica por qué faltan esos datos.

A entregar (Actividad 2)

Utilice la base tidy construida en la Actividad 1 para obtener una tabla resumen con el valor promedio, el máximo, el mínimo y la desviación estándar de la variable numérica correspondiente. Copie la tabla y el código en una nueva hoja del Excel de la Actividad 1.

7. Actividad 3: aplicación a sus propios datos

Use una base relacionada con su tesis, trabajo o área de interés.

Antes de escribir el diagnóstico, dele a su objeto un nombre propio y descriptivo (por ejemplo *tesis.laura* o *muestras.suelo*), en vez de dejarlo llamado "datos". La imagen de abajo lo marca con *mi.nombre* — reemplace ese texto por el nombre que usted eligió y úselo en el resto del código.

7.1 Diagnóstico mínimo

```
Seccion 7.1 - diagnostico minimo (escribir a mano, no copiar/pegar)
1  datos <- read_excel("mis_datos.xlsx")
2  mi.nombre <- datos
3
4  # reemplace "mi.nombre" por un nombre propio y descriptivo
5
6  dim(mi.nombre)
7  names(mi.nombre)
8  str(mi.nombre)
9  summary(mi.nombre)
10 colSums(is.na(mi.nombre))
11
12 # convertir al menos una variable categorica a factor:
13 mi.nombre$NOMBRE_VARIABLE <- factor(mi.nombre$NOMBRE_VARIABLE)
14 levels(mi.nombre$NOMBRE_VARIABLE)
```

7.2 Resumen agrupado

```
Seccion 7.2 - resumen agrupado (escribir a mano, no copiar/pegar)
1  resumen <- mi.nombre %>%
2    group_by(VARIABLE_CATEGORICA) %>%
3    summarise(
4      promedio = mean(VARIABLE_NUMERICA, na.rm = TRUE),
5      desviacion = sd(VARIABLE_NUMERICA, na.rm = TRUE),
6      n = n()
7    )
```

Antes de ejecutar, escriba: cuántos grupos espera, cuántas filas debería tener la tabla final y qué representa cada fila del resumen.

7.3 Crear y guardar un subconjunto

```
Sección 7.3 - subconjunto guardar (escribir a mano, no copiar/pegar)
1 grupo.mio <- mi.nombre %>%
2   filter(VARIABLE_CATEGORICA == "NIVEL_ELEGIDO")
3
4 write.csv(
5   grupo.mio,
6   "grupo.mio.csv",
7   row.names = FALSE
8 )
```

Verifique el resultado con `dim()`, `summary()` y `View()`. Explique si conserva todas las columnas y por qué cambió el número de filas.

7.4 Visualizar el resumen

Un resumen numérico también se puede "imaginar" antes de verlo: ¿qué categoría esperaría que tuviera la barra más alta? ¿Y la más baja? Grafique el resumen de 7.2 y compare con lo que predijo.

```
Sección 7.4 - visualizar resumen (escribir a mano, no copiar/pegar)
1 library(ggplot2)
2
3 ggplot(resumen, aes(x = VARIABLE_CATEGORICA, y = promedio)) +
4   geom_col(fill = "steelblue") +
5   labs(x = "", y = "promedio")
6
7 # si prefiere ver la distribucion completa, no solo el promedio:
8 ggplot(mi.nombre, aes(x = VARIABLE_CATEGORICA, y = VARIABLE_NUMERICA))
9   geom_boxplot()
```

8. El "test" de predicción

Para cada transformación importante (7.2; 7.3; 7.4), complete (mentalmente, o por escrito) esta ficha antes de ejecutar el código:

Objeto inicial	
Qué representa una fila inicialmente	
Operación que se aplicará	
Número esperado de filas	
Número esperado de columnas	
Qué representará una fila al final	

¿Aparecerán NA? ¿Por qué?	
A entregar (Actividad 3) Envíenme un Excel con SUS datos, y en una hoja nueva, la tabla resumen generada junto con el código que usaron.	

9. Video individual — máximo 2 minutos

El video es la evidencia principal de comprensión. No se evaluará edición, estética, cámara ni actuación. Le puede servir ir respondiendo, en orden, estos puntos:

1. Qué representa una fila en el archivo desordenado que le asignaron (antes de ordenarlo).
2. Qué problema tenía ese archivo.
3. Cómo reorganizó la información en formato tidy.
4. Qué variable utilizó para formar grupos.
5. Qué variable numérica resumió.
6. Qué hace `group_by()`.
7. Qué hace `summarise()`.
8. Cuántas filas esperaba obtener y qué representa cada fila final.
9. Qué subconjunto creó y cómo lo guardó.
10. Si el resultado coincidió con su predicción y cómo comprobó que tenía sentido.

Guion sugerido:

"Mi base contiene... Cada fila representa... El archivo original estaba organizado de esta manera... Lo transformé porque... Usé `group_by()` para... y `summarise()` para... Antes de ejecutar esperaba... El resultado mostró... Finalmente filtré... y guardé..."

10. Evaluación

Criterio	Indicador	Ponderación
Comprensión de la estructura	Identifica observaciones, variables, factores y problemas del archivo original.	20%
Transformación a tidy	Justifica cómo y por qué reorganizó el Excel asignado.	20%
<code>group_by()</code> y <code>summarise()</code>	Explica correctamente ambas funciones y la forma del resultado.	25%
Predicción y comprobación	Compara lo esperado con lo obtenido y reconoce posibles errores.	15%
Subconjunto y exportación	Explica el filtro, el archivo generado y su ubicación.	10%
Claridad oral	Explicación personal, comprensible y ajustada al tiempo.	10%

11. Microexposición para la próxima clase

En la clase del miércoles 29 de julio, cada estudiante presentará un paquete de R en un máximo de 2 minutos. Los paquetes serán asignados para evitar repeticiones (los sortearemos).

- ¿Qué problema resuelve?
- ¿Qué tipo de objeto o datos recibe?
- ¿Qué tipo de objeto, tabla, gráfico o resultado devuelve?
- ¿Cuál es una función representativa?
- ¿En qué situación sería excelente usarlo?
- ¿En qué situación no tendría sentido usarlo?

Regla final: no basta decir que un paquete "sirve para analizar datos". Debe quedar claro qué entra, qué hace y qué sale.

Anexo — Asignación de archivos por línea de investigación

Cada archivo tiene una estructura distinta, usen la que corresponde a su línea de trabajo.

N°	Línea de investigación	Archivo asignado
1	anti-tripanosoma	data1_antitripanosoma.xlsx
2	alimentación animal	data2_alimentacion_animal.xlsx
3	control biológico, insectos parasitoides	data3_control_biologico_parasitoides.xlsx
4	cáncer, acción antitumoral	data4_cancer_antitumoral.xlsx
5	membrana celular, transportador de metales pesados	data5_membrana_metales.xlsx
6	microbioma de la vid	data6_microbioma_vid.xlsx
7	fiordo Comau, microbioma degradación plástico	data7_fiordo_comau_plastico.xlsx
8	viroma suelo, cambio de estructura	data8_viroma_suelo.xlsx
9	compuestos bioactivos semilla quinoa (fungicida/antioxidante)	data9_quinoa_bioactivos.xlsx